



جامعة اللاذقية

كلية الهندسة المعلوماتية

قسم البرمجيات ونظم المعلومات

هندسة نظم المعلومات

تحليل أثر الذكاء الاصطناعي

على الأداء الأكاديمي للطلاب

AI Student Impact Dataset

إعداد الطلاب:

فرح خالد خدام فرح عبدالناصر غلاونجي

الاء خالد عيروط عبدالرحمن خالد حداد

عمار محمد عمران

إشراف:

د. هبة أبو أحمد

2025 – 2026

مقدمة :

تتضمّن هذه الدراسة مجموعة بيانات تحتوي على خمسين ألف سجل لطلاب جامعيين، يصف كل سجل منها سلوك طالب في استخدام أدوات الذكاء الاصطناعي خلال فصل دراسي، إلى جانب معلومات عن مستواه الأكاديمي، وعدد ساعات دراسته التقليدية، ودرجة اعتماده على هذه الأدوات، وغيرها من المتغيرات ذات الصلة.

انطلاقاً من هذه البيانات، يهدف المشروع إلى الإجابة عن سؤال محوري: هل يؤثر استخدام الذكاء الاصطناعي على المعدل الدراسي للطلاب؟ وللإجابة عنه، جرى تنظيف البيانات وتهيئتها أولاً، ثم تحليلها باستخدام نموذجين: الأول لتجميع الطلاب في فئات متشابهة واكتشاف الأنماط بينهم، والثاني للتنبؤ بالمستوى الأكاديمي للطلاب بناءً على سلوكه.

البيانات :

تتكوّن مجموعة البيانات من خمسين ألف سجل طالب جامعي، وستة عشر عموداً، أبرز هذه الأعمدة :

المعدل الدراسي Pre_Semester_GPA - Post_Semester_GPA

استخدام الذكاء الاصطناعي Weekly_GenAI_Hours - Primary_Use_Case - Tool_Diversity

الدراسة التقليدية Traditional_Study_Hours - Perceived_AI_Dependency

الجانب النفسي Anxiety_Level_During_Exams - Burnout_Risk_Level
Skill_Retention_Score

رُكّز المشروع على التنبؤ بقيمة Post_Semester_GPA لأنه يمثّل معدل الطالب في نهاية الفصل، وهو الأثر المباشر الذي نريد دراسته.

Data Preprocessing

مرّت البيانات بثلاث خطوات متسلسلة لتجهيزها

الخطوة الأولى : Encoding

لا تستطيع خوارزميات التعلم الآلي التعامل مع النصوص مباشرةً، لذا حوّلنا جميع الأعمدة النصية إلى أرقام:

- Year_of_Study أصبح 1=Freshman و 2=Sophomore وصولاً إلى 5=Graduate
- Burnout_Risk_Level أصبح 1=Low و 2=Medium و 3=High
- Prompt_Engineering_Skill أصبح 1=Beginner و 2=Intermediate و 3=Advanced
- Paid_Subscription أصبح 1=True و 0=False
- Major_Category و Primary_Use_Case و Institutional_Policy حوّلناها إلى أعمدة منفصلة بقيم 0 و 1
- أسقط عمود Student_ID لكونه مجرد معرف لا قيمة تحليلية له

الخطوة الثانية : Outliers Handling

بعض السجلات تحتوي على قيم غير منطقية تؤثر على دقة التحليل، كطالب يستخدم الذكاء الاصطناعي أكثر من ساعات الأسبوع كلها. للتعامل مع هذه القيم استخدمنا طريقة IQR ، التي تحدد الحد الأدنى والأعلى المقبولين لكل عمود، وأي قيمة تتجاوز هذه الحدود يتم تقليصها للحد الأقرب إليها بدلاً من حذف السجل كاملاً. طُبّق ذلك على الأعمدة التالية:

- Pre_Semester_GPA و Post_Semester_GPA
- Weekly_GenAI_Hours و Traditional_Study_Hours
- Perceived_AI_Dependency و Skill_Retention_Score
- Anxiety_Level_During_Exams و Tool_Diversity

الخطوة الثالثة : Normalization

الأعمدة المختلفة لها مقاييس مختلفة، ف Weekly_GenAI_Hours قد تصل إلى 40 بينما Post_Semester_GPA لا تتجاوز 4. هذا الفارق يجعل الخوارزمية تعطي وزناً أكبر للأعمدة ذات القيم الكبيرة بغض النظر عن أهميتها الحقيقية. لذا طبقنا MinMax Scaling على الأعمدة الرقمية المستمرة لتحويل جميع قيمها إلى نطاق موحد بين 0 و1:

- Post_Semester_GPA و Pre_Semester_GPA
- Traditional_Study_Hours و Weekly_GenAI_Hours
- Skill_Retention_Score و Perceived_AI_Dependency
- Anxiety_Level_During_Exams و Tool_Diversity

Data Mining Algorithms

بعد تجهيز البيانات ومعالجتها، جاءت مرحلة التحليل الفعلي واستخراج الأنماط، وتضمنت نموذجين:

النموذج الأول - K-Means Clustering

هدفه تجميع الطلاب في مجموعات متشابهة بناءً على سلوكهم الدراسي واستخدامهم للذكاء الاصطناعي، دون الاعتماد على أي تصنيف مسبق.

مرّ التطبيق بخطوتين:

الخطوة الأولى : تحديد عدد المجموعات: استُخدمت طريقة Elbow Method بتجربة قيم K من 1 إلى 10، وقياس نسبة الخطأ عند كل قيمة. عند رسم النتائج يظهر منحنى يشبه شكل الكوع – والنقطة التي يبدأ عندها الانحدار بالتباطؤ هي العدد الأمثل للمجموعات.

الخطوة الثانية : تطبيق الخوارزمية: بعد تحديد K، طُبِّقت خوارزمية K-Means على البيانات، فأُسندت لكل طالب مجموعة يشبه أعضائها في سلوكه. النتيجة أُضيفت كعمود جديد Student_Group لكل سجل وحُفظت في ملف students_with_clusters.csv.

النموذج الثاني – Decision Tree Classification

هدفه التنبؤ بالمستوى الأكاديمي للطالب بناءً على سلوكه. وبما أن Post_Semester_GPA قيمة رقمية مستمرة، قُسمت أولاً إلى ثلاث فئات:

- Low: معدل أقل من 2.5
- Medium: معدل بين 2.5 و3.3
- High: معدل أعلى من 3.3

بعدها قُسمت البيانات إلى 80% للتدريب و20% للاختبار، ثم بُني النموذج الذي يتعلم من بيانات التدريب كيف يصنّف الطالب بناءً على أعمدة مثل Weekly_GenAI_Hours وTraditional_Study_Hours وAnxiety_Level_During_Exams وغيرها. وفي النهاية قُيّم أدائه على بيانات الاختبار التي لم يرها من قبل.